

TP1 - Statistique avec R - Rappels dplyr du S1

OBJECTIFS DU TP :

Le but de ce TP est de s'assurer que tout le monde est capable de manipuler un jeu de données. C'est aussi l'occasion de revoir la syntaxe pour simuler des lois de probabilités.

Exercice 1

Pour cet exercice, vous pouvez travailler au choix avec dplyr et/ou en R base.

Les données utilisées sont des données communales issues du recensement de la population pour l'année 2019. Les données contiennent des variables relatives au zonage en aires d'attraction des villes (AAV). Ce zonage remplace le zonage en aires urbaines. Une aire d'attraction des villes est constituée d'un pôle et d'une couronne. Le pôle peut regrouper plusieurs communes en fonction de leur densité et du niveau d'emploi. Les communes qui envoient au moins 15 % de leurs actifs travailler dans le pôle constituent la couronne de l'aire. Certaines communes ne font ni parties d'un pôle ni d'une couronne, on dit qu'elles sont hors attraction des villes. Si nécessaire, vous trouverez des informations sur ce zonage en cliquant [ici](#)

La table `communes_2019` contient les variables suivantes :

- `codgeo` = code commune
- `libgeo` = libellé de la commune
- `pop2019` = population totale 2019
- `popXY_2019` = population de la tranche d'âge [X,Y[
- `typoAAV20` = type d'aire à laquelle la commune est rattachée
- `grilledens7` = catégorie dans la grille de densité à 7 niveaux
- `libaav20` = libellé de l'aire à laquelle est rattachée la commune
- `tx_evol_annuel_1319` = Taux de croissance annuel moyen de la population entre 2013 et 2019

Le dictionnaire de la variable “`typoAAV20`” est le suivant :

libtypo	typoaaav20
Commune appartenant à la couronne d'un pôle de moins de 50 000 habitants	T01_20
Commune isolée hors influence des pôles	T00_30
Commune appartenant à un pôle de moins de 50 000 habitants	T01_10
Commune appartenant à la couronne d'un pôle de 700 000 habitants ou plus	T45_20
Commune appartenant à la couronne d'un pôle entre 50 000 et 200 000 habitants	T02_20
Commune appartenant à un pôle entre 50 000 et 200 000 habitants	T02_10
Commune appartenant à la couronne d'un pôle entre 200 000 et 700 000 habitants	T03_20
Commune appartenant à un pôle entre 200 000 et 700 000 habitants	T03_10
Commune appartenant à un pôle de 700 000 habitants ou plus	T45_10

Partie A

1. Importer le fichier “`communes_2019.csv`”. Afficher un descriptif de cette table. Le type des variables vous semble-t-il bon ? Faire les modifications si nécessaires.
2. Renommer la variable “`pop7582019`” en “`pop75plus_2019`”.
3. En utilisant la fonction `factor()`, créer une variable `grilledens` qui correspondra à la variable `grilledens7` mise en factor. Les labels seront les suivants : 1 = “Grands centres urbains” 2 = “Centres urbains intermédiaires” 3 = “Petites villes” 4 = “Ceintures urbaines” 5 = “Bourgs ruraux” 6 = “Rural à habitat dispersé” 7 = “Rural à habitat très dispersé”.

4. Conserver uniquement les communes de Provence-Alpes-Côte d'Azur (PACA) dont les 2 premiers chiffres du CODGEO commencent par 04, 05, 06, 13, 83, 84. Ce nouveau dataframe s'appellera "communes_paca".
5. La base contient-elle des doublons ? Si oui, les enlever.
6. Combien y a-t-il d'habitants en PACA ?
7. Si cela n'a pas déjà été fait, créer une variable de département correspondant aux 2 premiers chiffres du codegeo. Calculer ensuite la population par département.
8. Importer le fichier "dico_aav20.csv". Faire la jointure de cette table avec votre dataframe communes_paca.
9. Créer une variable "i_64p_m20" qui sera égale au nombre d'habitants de plus de 64 ans/population de moins de 20 ans. Afficher un résumé statistique de cette variable.
10. Faire un boxplot de cette variable selon le département.
11. En utilisant, la variable de taux d'évolution annuel, créer la variable pop2013. Vous arrondirez le résultat, de sorte qu'il n'y ait pas décimale.

Partie B

12. Combien d'AAV différentes existe-t-il en PACA (utiliser la variable libaav20) ? Afficher les AAV présentes dans plusieurs départements ?
13. Créer un dataframe "aav20_paca" contenant uniquement les Aires d'Attraction des Villes de PACA. L'unité statistique sera donc l'AAV (une ligne = un AAV différent)

Ce dataframe contiendra les variables suivantes : le code de l'AAV et son libellé (variable libaav20), le nombre de communes qu'il contient (nb_communes), sa population totale (poptotale), la part de sa population vivant dans une commune rurale (part_com_rurale), la part de sa population dans une commune urbaine (part_com_urbaine). On considèrera qu'une commune est rurale si grillessens7 vaut "Bourgs ruraux", "Rural à habitat dispersé" ou "Rural à habitat très dispersé". Sinon, la commune est considérée comme urbaine.

Exercice 2

Soit un centre hospitalier contenant 5000 patients pour 10 machines respiratoires. Un épidémiologiste a estimé que la probabilité pour un patient d'avoir un accident cardiaque était de 1/1000.

1. Calculer la probabilité que ce centre soit en tension sur une journée (pas assez de machines respiratoires pour le nombre de patients en ayant besoin).
2. Au vu du résultat précédent, sur une année de 365 jours, à combien de jours de tensions peut-on s'attendre ? On supposera que chaque journée est indépendante des précédentes.
3. Retrouver un résultat similaire à celui calculé dans la question 2 en faisant une simulation. Pour cela, vous commencerez par simuler un vecteur de 365 observations, chaque élément désignant le nombre de patients ayant eu un accident cardiaque dans une journée. Vous commencerez votre code avec la commande suivante :

```
set.seed(1)
```

4. En s'inspirant de la simulation faite en question 3, compléter la phrase suivante : sur 10 ans, nous avons en moyenne . . . jours de tensions chaque année. Indication : Faites une boucle ! Cela revient à faire la simulation précédente 10 fois (mais ne copiez pas 10 fois le même code !) pour en calculer la moyenne. Pour cette question, vous enlèverez la graine (=suppression de la ligne set.seed(1))

Exercice 3

Un ascenseur a une capacité de 10 personnes et une charge maximale de 800 kg. On suppose que le poids des hommes suit une loi normale d'espérance 75 kg avec un écart-type de 12. On suppose que le poids des femmes suit également une loi normale d'espérance 65 kg avec un écart-type de 10. Par ailleurs, la probabilité qu'un individu soit un homme est de 0.504 et la probabilité d'être une femme est de 0.496. Le but de cet exercice est d'estimer la probabilité que l'ascenseur se trouve en surcharge avec 10 personnes.

1. A partir des informations précédentes, simuler un groupe de 10 personnes ainsi que son poids.
2. En utilisant les simulations de la question précédente, représenter la distribution du poids de l'ascenseur en simulant 500 groupes.
3. A partir de la question précédente, donner une estimation de la probabilité que l'ascenseur soit en surcharge.