

TP6 - Statistique avec R - Tests

OBJECTIFS DU TP :

Le but de ce TP est de s'initier à l'utilisation de quelques tests statistiques.

Travaillez soit sur le [cluster R](#) soit sur le [Datalab/Onyxia](#). Vous pouvez aussi librement choisir de coder sur un document Quarto `.qmd` (au sein de *chunks* donc) ou sur un script `.R` classique.

Commencer par charger votre Rprojet Stats_avec_R créé au TP1, puis affecter un nouveau dossier "TP6 tests". Pour importer vos données, cliquez sur le bouton Upload situé dans l'onglet Files, en dessous de votre environnement.

```
# Chargement des packages nécessaires
library(tidyverse)
library(MASS)
library(goftest)
library(readxl)
# install.packages("ellipse")
library(ellipse)
# install.packages("corrplot")
library(corrplot)
# install.packages("car")
library(car)
```

Exercice 1

Première partie : retour sur la régression linéaire (à p variables explicatives)

💡 Quelques rappels sur la régression linéaire multiple à p régresseurs

La régression linéaire est une méthode d'analyse statistique utilisée pour modéliser une variable à expliquer Y en fonction de plusieurs variables explicatives (disons p variables, en dehors de la constante).

La forme générale de la régression linéaire multiplie est représentée par l'équation :

$$Y_i = \beta_0 + \beta_1 \cdot X_{i1} + \beta_2 \cdot X_{i2} + \dots + \varepsilon_i$$

où :

- Y_i est la **variable à expliquer** (cible) pour l'individu i .
- X_{ij} désigne la j -ième **variable explicative (prédicteur)** X_j associée à l'individu i .
- β_0 est la **constante** du modèle, représentant la **valeur de Y lorsque $X = 0$** .
- β_j désigne le **coefficient associé à la variable X_j** , représentant le **changement de Y pour un changement unitaire de X_j** .
- ε_i est un **terme d'erreur qui représente la variation non expliquée par le modèle**. Dans le modèle, on le prend en compte via un terme **aléatoire**, plus exactement via des **réalisations indépendantes d'une variable aléatoire normale, supposée centrée et de variance σ^2 (homoscédasticité)** : $\varepsilon_i \stackrel{i.i.d}{\sim} \mathcal{N}(0, \sigma^2)$

Les coefficients β_j associés à chaque variable explicative X_j peuvent être estimés par **MCO**. On obtient ainsi les **estimateurs sans biais** $\hat{\beta}_j$ qui auront quelques bonnes propriétés **sous l'hypothèse de normalité** des ε_i (notamment normalité et efficacité).

💡 Construction d'un intervalle de confiance $IC_{1-\alpha}(\beta_j)$ pour chaque coefficient β_j associé à X_j

On peut calculer un intervalle de confiance pour chaque coefficient estimé $\hat{\beta}_j$. **Sous l'hypothèse de normalité des erreurs**, $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$, et comme **la variance σ^2 est inconnue**¹, on peut réécrire chaque coefficient sous la forme d'une statistique T_j qui est supposée **suivre une loi de Student à $n - p - 1$ degrés de liberté** :

$$T_j = \frac{\hat{\beta}_j - \beta_j}{\hat{\sigma}(\hat{\beta}_j)} \sim \mathcal{T}(n - p - 1)$$

avec $\hat{\sigma}(\hat{\beta}_j)$: l'erreur standard estimée associée à l'estimation du coefficient β_j , que vous retrouvez en sortie de votre modèle ("Std. Error").

Sous cette hypothèse, en posant $t_{n-p-1, 1-\frac{\alpha}{2}}$ le quantile d'ordre $1 - \alpha/2$ d'une $\mathcal{T}(n - p - 1)$, on obtient **l'intervalle de confiance d'ordre $1 - \alpha$ pour chaque coefficient β_j associé à X_j** :

$$\mathbb{P}(|T_j| \leq t_{n-p-1, 1-\frac{\alpha}{2}}) = 1 - \alpha \Rightarrow IC_{1-\alpha}(\beta_j) = [\hat{\beta}_j - t_{n-p-1, 1-\frac{\alpha}{2}} \cdot \hat{\sigma}(\hat{\beta}_j) ; \hat{\beta}_j + t_{n-p-1, 1-\frac{\alpha}{2}} \cdot \hat{\sigma}(\hat{\beta}_j)]$$

💡 **Test de significativité, au risque α , du coefficient β_j associé à X_j**

Formulation des hypothèses du test

Pour chaque coefficient β_j , une hypothèse nulle (H_0) est formulée comme suit : $H_0 : \beta_j = 0$

Sous cette hypothèse nulle, le coefficient associé à la variable explicative X_j est nul, et donc **cette variable n'a aucun effet significatif sur la variable à expliquer Y** .

L'hypothèse alternative est : $(H_1) : \beta_j \neq 0$.

Il s'agit donc d'un **test bilatéral** (car 2 zones de rejet de H_0 : lorsque le coefficient est négatif et très différent de 0, et lorsque le coefficient est positif et très différent de 0).

Si (H_0) **est rejetée au risque α** , cela indique que X_j **a un effet significatif sur Y** .

La statistique de test

Pour tester (H_0) : $\beta_j = 0$ vs. (H_1) : $\beta_j \neq 0$, on utilise la statistique T_j mentionnée précédemment. Sous l'hypothèse nulle (H_0), T_j suit une loi de Student à $n - p - 1$ degrés de liberté, où n est le nombre d'observations et p est le nombre de variables explicatives (sans compter la constante) :

$$T_j = \frac{\hat{\beta}_j - \beta_j}{\hat{\sigma}(\hat{\beta}_j)} \stackrel{(H_0)}{=} \frac{\hat{\beta}_j}{\hat{\sigma}(\hat{\beta}_j)} \stackrel{(H_0)}{\sim} \mathcal{T}(n - p - 1)$$

Règle de décision : via la p-valeur ou la zone de rejet $\mathcal{R}_\alpha^{(H_0)}$

En calculant $t_j = T_{j,obs}$ à partir de l'échantillon observé $(y_i; x_{ij})_{1 \leq i \leq n, 1 \leq j \leq p}$, on peut au choix :

- calculer la zone de rejet $\mathcal{R}_\alpha^{(H_0)}$ en comparant t_j au quantile $t_{n-p-1, 1-\frac{\alpha}{2}}$: si $t_j \in \mathcal{R}_\alpha^{(H_0)} = \{|T_j| > t_{n-p-1, 1-\frac{\alpha}{2}}\} = \mathbb{R} \setminus IC_{1-\alpha}(\beta_j)$, on rejettera (H_0) au risque α , ie. on "accepterait" donc l'hypothèse (H_1) d'**effet significatif de la variable X_j sur la réponse Y au risque α** .
- calculer la **p-valeur α^* associée au test bilatéral** : c'est la **plus petite valeur pour laquelle on rejettera (H_0)**. Mathématiquement : $\alpha^* = \inf_{\alpha \in [0;1]} \{T_j \in \mathcal{R}_\alpha^{(H_0)}\}$. La p-valeur se calcule en imposant l'égalité au sein de $\mathcal{R}_\alpha^{(H_0)}$: $\alpha^* \text{ tq } |t_j| = t_{n-p-1, 1-\frac{\alpha^*}{2}} = F_{\mathcal{T}(n-p-1)}^{-1}(1 - \frac{\alpha^*}{2}) \Rightarrow$

$$\alpha^* = 2 \cdot [1 - F_{\mathcal{T}(n-p-1)}(t_j)] = 2 \cdot \mathbb{P}_{(H_0)}(T_j > |t_j|) \text{ avec } T_j \stackrel{(H_0)}{\sim} \mathcal{T}(n - p - 1).$$

En pratique, après avoir fixé le risque α de première espèce, on préfère très souvent utiliser la p-valeur (via le calcul de α^*) comme règle de décision, car elle apporte bien plus d'information que de déterminer la zone de rejet $\mathcal{R}_\alpha^{(H_0)}$ qui ne donnera que la décision pour la seule valeur du risque α choisi. Pour la p-valeur α^* , plus petite valeur α pour laquelle on rejettera (H_0) :

- Si $\alpha^* \leq \alpha$, **on rejette (H_0)** : cela signifie que β_j est significativement différent de 0.
- Si $\alpha^* > \alpha$, **on ne peut pas rejeter (H_0)**, ce qui indique que β_j n'est pas significativement différent de 0, et donc que **la variable X_j n'a pas d'effet significatif sur la réponse Y** .

1. Si la variance σ^2 était connue, on pourrait utiliser directement la gaussienne $Z_j = \frac{\hat{\beta}_j - \beta_j}{\sigma(\hat{\beta}_j)} \sim \mathcal{N}(0, 1)$ où $\sigma(\hat{\beta}_j)$ dépend de σ . En estimant σ^2 par $\hat{\sigma}_{MCO}^2 := \frac{1}{n-p-1} \sum_{i=1}^n (y_i - \hat{y}_i)^2$, on perd la normalité (cf. cours de Stat Inférentielle).

Exercice 1

Reprenez les données d'abstentions du précédent TP et lancez le code suivant :

```
library(dplyr)

abstentions_sans_vm <- read.csv2("abstentions.csv") %>%
  mutate(across(.cols = -1, .fns = as.numeric)) %>% # warning : 6 NA introduced by coercion
  filter(if_all(.cols = everything(), .fns = ~!is.na(.))) %>%
  dplyr::select(-ABS_EUR_2019)
```

0. Utilisez la fonction `lm()` pour modéliser l'abstention aux présidentielles en utilisant l'ensemble des variables explicatives (**sauf celle du département**). Quelles variables semblent être explicatives de l'abstention ? On considèrera qu'une variable est explicative si sa p -value < 0.05 .
1. On rappelle que l'estimation des coefficients peut être délicate lorsque **certaines variables explicatives sont corrélées entre elles**. Refaites le même modèle en retirant la variable `PART_65PLUS`. Remarque : vous n'êtes pas obligés de renseigner le nom de toutes les variables explicatives. Vous pouvez utiliser la syntaxe suivante : `lm(ABS_PRES_2022 ~ . - PART_65PLUS, data=ma_table)` ou retirer la variable de la table et utiliser : `lm(ABS_PRES_2022 ~ ., data=ma_table)`. Y a-t-il des changements dans la significativité des coefficients ?
2. Calculer les p -values associés aux coefficients de ce modèle en utilisant les formules de rappels de l'énoncé. Pour cela, modifier/compléter le code suivant :

```
t_values <- mon_model$coefficients / summary(mon_model)$coefficients[, "Std. Error"]
# Nombre de degrés de liberté
n <-      # Nombre d'observations
p <-      # Nombre de variables explicatives (hors constante)
ddl <-    # Degrés de liberté

# Calcul des p-values
p_values <- 2 * ... (1-abs(ma_statistique_de_test), df = ddl)
p_values
```

💡 Test F de validité globale du modèle : $(H_0) : \beta_1 = \beta_2 = \dots = \beta_p = 0, 1 \leq j \leq p$

Le **test de validité globale du modèle**, ou encore **test de significativité globale des variables explicatives**, consiste à tester l'hypothèse nulle de **nullité simultanée de l'ensemble des coefficients β_j associés aux variables X_j** . L'hypothèse alternative est : au moins un des coefficients est différent de 0. Autrement dit, on cherche à savoir si le modèle est **significativement différent de la constante β_0** . Si ce n'est pas le cas, cela indiquerait que les covariables n'ont aucune influence sur la variable réponse Y . À risque α fixé, la formulation du test est la suivante :

$$(H_0) : \beta_1 = \beta_2 = \dots = \beta_p = 0, 1 \leq j \leq p \text{ vs. } (H_1) : \exists j \neq l, \beta_j \neq \beta_l$$

La statistique de test utilisée correspond à celle du **test de Fisher** (*F-statistic*), notamment utilisée pour tester l'égalité des variances, qui suivra une loi de Fisher de paramètres $(p, n - p - 1)$ sous H_0 :

$$F = \frac{SCE/p}{SCR/(n-p-1)} = \frac{n-p-1}{p} \frac{R^2}{1-R^2} \stackrel{(H_0)}{\sim} \mathcal{F}(p; n-p-1)$$

La p -valeur du test est donnée par : $\alpha^* = 1 - F_{\mathcal{F}(p; n-p-1)}(F_{obs}) = \mathbb{P}_{(H_0)}(F > F_{obs})$ où F_{obs} est la valeur de la statistique observée sur l'échantillon, avec $F \stackrel{(H_0)}{\sim} \mathcal{F}(p; n-p-1)$.

3. Tout en bas de la sortie `summary` de la question 1, vous avez dû voir une p -value à côté d'une "*F-statistic*". À vous de retrouver, au vu de la sortie, la p -value associée à ce test, en utilisant la fonction `pf()`. Concluez : le modèle actuel est-il meilleur que le modèle "nul" (modèle uniquement constitué de la constante) ?
4. La variable de `SOLDE_MIGRATOIRE` ne ressortait pas toujours comme significative pour expliquer l'abstention. On rappelle que le solde migratoire ne fait pas référence à la nationalité : c'est **la différence entre mes nouveaux arrivants dans le département et mes sortants**. Faites un

nuage de points pour représenter la relation entre ces deux variables puis calculer le **coefficient de corrélation linéaire (empirique)**² $\hat{\rho}_n$ de Pearson.

💡 **Test de corrélation linéaire de Pearson :** $(H_0) : \rho(X; Y) = 0$ vs. $(H_1) : \rho(X; Y) \neq 0$

Formulation du test : $(H_0) : \rho(X; Y) = 0$ (pas de corrélation linéaire entre les deux variables) vs. $(H_1) : \rho(X; Y) \neq 0$ (existence d'une corrélation linéaire entre les deux variables).

Ici, $\rho(X; Y) = \frac{\text{cov}(X; Y)}{\sigma(X) \sigma(Y)} \in [-1; 1]$ représente le coefficient de corrélation de Pearson dans la **population générale**. À partir de n -échantillon, on l'estime par le coefficient de corrélation **empirique** :

$$\hat{\rho}_n := \hat{\rho}_n(x; y) = \frac{c_{n,x,y}}{\sigma_{n,x} \sigma_{n,y}} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}_n)(y_i - \bar{y}_n)}{\sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}_n)^2} \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y}_n)^2}} \in [-1; 1]$$

Statistique de test :

$$T_\rho = \sqrt{n-2} \frac{\hat{\rho}_n - \rho}{\sqrt{1 - \hat{\rho}_n^2}} \stackrel{(H_0)}{=} \sqrt{n-2} \frac{\hat{\rho}_n}{\sqrt{1 - \hat{\rho}_n^2}} \stackrel{(H_0)}{\sim} \mathcal{T}(n-2)$$

Règle de décision : $\alpha^* = 2 \cdot [1 - F_{\mathcal{T}(n-2)}(t_\rho)] = 2 \cdot \mathbb{P}_{(H_0)}(T_\rho > |t_\rho|)$ avec $T_\rho \stackrel{(H_0)}{\sim} \mathcal{T}(n-2)$.

- On se demande si la valeur calculée précédemment $\hat{\rho}_n$ est significativement différente de 0. Utiliser la fonction `cor.test()` pour effectuer le test de corrélation de Pearson. Quel est le risque de rejeter (H_0) à tort ? S'agit-il d'un test bilatéral ?
- Retrouver les résultats obtenus avec la fonction `cor.test()` en calculant vous même la statistique de test t_ρ et la **p-value** α^* associée (comme si la fonction `cor.test()` n'existait pas).
- On se demande s'il existe un lien non linéaire entre ces deux variables. On se propose d'utiliser le **test de rangs de Spearman**. Vous trouverez une présentation du test **en fin de sujet**. Implémentez ce test avec la fonction `cor.test()`. Que peut-on conclure ?

2. Les versions **empiriques** des statistiques que vous calculez sont des **estimateurs, calculés à partir des données/de l'échantillon**. Leurs versions théoriques sont des quantités non calculables en pratique car généralement inconnues, représentant la **population générale** ciblée.

Exercice 2

Au cours de la séance de TP4 (sur l'inférence statistique), nous avons travaillé sur la table `quine` de la library `MASS`. Nous supposons notamment que la variable `Days` (jours d'absences dans un établissement scolaire) suivait une loi exponentielle de paramètre $\hat{\lambda} = 1/\bar{X}$. On souhaite **tester si la distribution de la variable `Days` suit une loi exponentielle de paramètre $\lambda = 0.06$** . Commencer par charger les données en lançant la commande suivante :

```
library(MASS) ; data(quine)
str(quine)
```

```
'data.frame':  146 obs. of  5 variables:
 $ Eth : Factor w/ 2 levels "A","N": 1 1 1 1 1 1 1 1 1 1 ...
 $ Sex : Factor w/ 2 levels "F","M": 2 2 2 2 2 2 2 2 2 2 ...
 $ Age : Factor w/ 4 levels "F0","F1","F2",...: 1 1 1 1 1 1 1 1 2 2 ...
 $ Lrn : Factor w/ 2 levels "AL","SL": 2 2 2 1 1 1 1 1 2 2 ...
 $ Days: int  2 11 14 5 5 13 20 22 6 6 ...
```

On cherche à savoir si la variable `Days` suit une loi exponentielle de paramètre 0.06.

1. Implémenter le **test de Kolmogorov-Smirnov** à l'aide de la fonction `ks.test()`. Vous trouverez une présentation de ce test **en fin de sujet**.
2. Le test de Kolmogorov-Smirnov peut être **sensible aux valeurs aberrantes puisque sa statistique de test repose sur une valeur locale (la différence maximale)**. On propose donc d'utiliser le **test de Cramer-Von Mises** qui considère l'écart entre la fonction de répartition théorique et la fonction de répartition empirique sur l'ensemble des valeurs. Vous trouverez une présentation **en fin de sujet**. Utiliser la fonction `cvm.test()` du package `goftest` pour **tester si la série suit bien une loi exponentielle de paramètre 0.06**.
3. Pour avoir un 3e avis, on propose maintenant de faire le **test d'Anderson-Darling** qui permet **d'identifier des écarts dans les queues de distributions**. Pour cela, utiliser la fonction `ad.test()` du package `goftest` sur le même modèle que pour la question précédente. Vous trouverez une présentation du test **en fin de sujet**.

Exercice 3

On s'intéresse aux notes d'anciens étudiants de l'Ensa au cours de statistique exploratoire uni et bivariée.

1. On se demande s'il existe un **lien entre le sexe et la note à l'examen**. Quel graphique pouvez-vous utiliser pour observer un éventuel lien ?
2. On cherche à savoir **si la moyenne des garçons est significativement différente de celle des filles au seuil de 5 %**. Pour cela, on envisage d'effectuer un **test de student de comparaison de moyennes**. Une condition de ce test est d'avoir une variable quantitative **suivant une loi normale au sein de chaque groupe**. Utiliser le **test de Shapiro-Wilk** et la fonction R associée `shapiro.test()` pour tester si cette condition est vérifiée. Pour le test de Shapiro-Wilk, **sous (H_0) la distribution suit une loi normale : $(H_0) : F = F_0 = \mathcal{N}(\mu; \sigma^2), \mu \in \mathbb{R}, \sigma^2 > 0$ quelconques.**

💡 Test d'égalité des variances de Fisher : $(H_0) : \sigma_1^2 = \sigma_2^2$ vs. $(H_1) : \sigma_1^2 \neq \sigma_2^2$

Formulation du test : $(H_0) : \sigma_1^2 = \sigma_2^2$ (égalité des variances entre les deux populations) vs. $(H_1) : \sigma_1^2 \neq \sigma_2^2$ (différence de variances entre les deux populations).

Ici, σ_1^2 et σ_2^2 représentent les variances de deux **populations générales** (supposées **indépendantes et de distributions normales**). À partir de deux échantillons de tailles n_1 et n_2 , on peut estimer les variances inconnues par les **variances empiriques corrigées** (non biaisées) $S_{1,n}^2$ et $S_{2,n}^2$:

$$S_{1,n}^2 = \frac{1}{n_1 - 1} \sum_{i=1}^{n_1} (X_{1,i} - \bar{X}_1)^2 \quad \text{et} \quad S_{2,n}^2 = \frac{1}{n_2 - 1} \sum_{i=1}^{n_2} (X_{2,i} - \bar{X}_2)^2$$

Statistique de test :

$$F = \frac{S_{1,n}^2 / \sigma_1^2}{S_{2,n}^2 / \sigma_2^2} \stackrel{(H_0)}{=} \frac{S_{1,n}^2}{S_{2,n}^2} \stackrel{(H_0)}{\sim} \mathcal{F}(n_1 - 1, n_2 - 1)$$

Règle de décision : $\alpha^* = 2 \cdot \min [\mathbb{P}_{(H_0)}(F \leq f_{obs}), \mathbb{P}_{(H_0)}(F \geq f_{obs})]$ avec $F \stackrel{(H_0)}{\sim} \mathcal{F}(n_1 - 1, n_2 - 1)$.

3. Une **autre condition pour effectuer le test de student de comparaison de moyennes est d'avoir une variance similaire au sein des 2 groupes**. On propose donc de **tester si la variance des notes pour les garçons est similaire à celle des filles** : $(H_0) : \sigma_H^2 = \sigma_F^2$ vs. $(H_1) : \sigma_H^2 \neq \sigma_F^2$. Pour cela, effectuer un test de Fisher à l'aide de la fonction `var.test()`. Peut-on rejeter l'hypothèse d'égalité des variances au seuil de 5% ?
4. Effectuer le **test de student de comparaison de moyennes**. La fonction à utiliser est la fonction `t.test()`. Quelle est l'hypothèse nulle de ce test ? S'agit-il d'un test unilatéral ou bilatéral ? Que concluez-vous au vu de la sortie R ?
5. On se demande maintenant s'il y a un **lien entre la voie d'accès au concours et le sexe**. Dit autrement, on se demande **si les filles (respectivement les garçons) sont surreprésentés au sein de certaines filières d'origine (Maths, Eco, Interne, AST)**. Afficher le tableau de contingence des variables de sexe et de voie d'accès. Quel outil numérique du 1er semestre (UE Stat descriptive) avez-vous vu pour analyser le lien entre 2 variables qualitatives ?
6. On propose d'effectuer un **test du Khi-2 pour analyser le lien entre ces 2 variables**. Pour cela, utiliser la fonction `chisq.test()`. Quelle est l'hypothèse nulle et la statistique de test ? Que conclure au vu de la sortie R ?
7. Une **condition pour que le test du khi-2 soit valide est que les effectifs théoriques de chaque case du tableau de contingence soient >5**. Cette condition est-elle respectée ? Pour cela, refaites le test du khi-2 en stockant cela dans un objet `mon_objet_test_X2`. Pour accéder, aux effectifs théoriques, utilisez la syntaxe suivante `mon_objet_test_X2$expected`
8. On cherche maintenant à étudier le **lien entre la note à l'examen et la voie d'accès**. Représenter graphiquement la note à l'examen en fonction de la voie d'accès.
9. On cherche à **tester l'égalité des moyennes entre les voies d'accès pour savoir si une filière réussit significativement mieux que les autres**. Lorsque la variable qualitative contient plus de 2 modalités, on n'utilise plus le test de student du début d'exercice : on privilégie un **test ANOVA (ANalyse Of VAriance)**. Vous trouverez une présentation du test ANOVA **en fin de sujet**. Utiliser la fonction `aov()` pour faire le test ANOVA.

10. Faire un **test de Shapiro-Wilk** pour tester si les résidus sont bien normalement distribués. Pour récupérer les résidus, vous pouvez adapter la syntaxe suivante `resid(mon_objet_aov)`.
11. Tester maintenant la condition d'homogénéité des variances avec le **test de Bartlett** (fonction `bartlett.test()`)

`?bartlett.test`

12. Le test ANOVA nous dit qu'il y a au moins un groupe qui diffère des autres (rejet de H_0). Pour **identifier lesquels s'écartent des autres, on fait un test de Tukey**. Le test de Tukey, également appelé test HSD (Honestly Significant Difference), est une méthode de comparaison multiple utilisée après une ANOVA.

Ce test permet de déterminer **quelles paires de moyennes diffèrent significativement lorsqu'une ANOVA détecte une différence globale significative entre les groupes**. Vous trouverez de la documentation sur ce test ici https://en.wikipedia.org/wiki/Tukey%27s_range_test.

Effectuer le test en modifiant la syntaxe suivante : `TukeyHSD()` sur le modèle suivant : <https://www.statology.org/tukey-test-r/>.

Que conclure ?

Annexes Exercice 1 : le test de rangs de Spearman

Hypothèses du test :

- **Hypothèse nulle** (H_0) : Les deux variables sont indépendantes (pas de relation monotone).
- **Hypothèse alternative** (H_1) : Il existe une relation monotone (croissante ou décroissante) entre les deux variables.

Calcul du coefficient de Spearman (r_s)

Le coefficient de Spearman (r_s) est basé sur les rangs des observations, et il est défini par :

$$r_s = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)},$$

où :

- d_i est la différence entre les rangs des observations de deux variables ($d_i = R(X_i) - R(Y_i)$),
- n est le nombre total d'observations.

Statistique de test

Si la taille de l'échantillon est assez grande, sous l'hypothèse nulle (H_0), le coefficient r_s suit approximativement une loi normale après transformation. La statistique de test est donnée par : $z = \frac{r_s \sqrt{n-1}}{\sqrt{1-r_s^2}}$. Cette statistique suit une loi normale standard ($\mathcal{N}(0, 1)$) sous H_0 .

Calcul de la p-valeur

- Pour un test bilatéral, la p-valeur est donnée par :

$$\text{p-valeur} = 2 \cdot P(Z > |z|)$$

où Z suit une loi normale standard.

- Si la p-valeur est inférieure au seuil α (ex. 0.05), on rejette H_0 , indiquant une corrélation monotone significative.

Interprétation

- $r_s > 0$: Relation monotone **croissante** (les valeurs de x augmentent avec y).
- $r_s < 0$: Relation monotone **décroissante** (les valeurs de x diminuent avec y).
- $r_s = 0$: Pas de relation monotone.

Annexes Exercice 2 : le test de Kolmogorov-Smirnov

Objectifs

Le test de Kolmogorov-Smirnov (KS) est un test statistique non paramétrique utilisé pour comparer une distribution observée à une distribution théorique (test d'ajustement) ou pour comparer deux distributions empiriques. Concrètement, il mesure la différence maximale qui existe entre la fonction de répartition observée et celle théorique.

On l'utilise donc pour :

- Si une série de données suit une loi théorique donnée (ici une loi exponentielle)
- Comparer deux échantillons pour déterminer s'ils proviennent de la même population.

Hypothèses

1. Test d'ajustement :

- **Hypothèse nulle (\$ H_0 \$)** : Les données suivent la distribution théorique spécifiée.
- **Hypothèse alternative (\$ H_1 \$)** : Les données ne suivent pas la distribution théorique spécifiée.

2. Test de comparaison :

- **(\$ H_0 \$)** : Les deux échantillons proviennent de la même distribution.
- **(\$ H_1 \$)** : Les deux échantillons proviennent de distributions différentes.

Fonctionnement

1. Calcul des fonctions de répartition :
 - $F_{\text{emp}}(x)$: Fonction de distribution empirique de l'échantillon.
 - $F_{\text{th}}(x)$: Fonction de distribution théorique ou empirique d'un autre échantillon.
2. On détermine la distance maximale entre les fonctions de répartition :
 - $D = \max |F_{\text{emp}}(x) - F_{\text{th}}(x)|$
3. On compare la statistique D à une valeur critique issue de la table du test de Kolmogorov-Smirnov.

Résultat

- Si D est supérieur à la valeur critique (ou si la p-valeur est inférieure au seuil de signification), on rejette H_0 .

Annexes Exercice 2 : le test de Cramer-Von Mises

Le test de Cramér-von Mises est un test statistique non paramétrique utilisé pour évaluer la conformité d'une distribution empirique à une distribution théorique donnée. C'est une alternative au test de Kolmogorov-Smirnov, mais il est plus sensible aux écarts sur toute la distribution (et pas seulement à la différence maximale).

Objectif (les mêmes que le test de Kolmogorov-Smirnov)

- Tester si un échantillon suit une loi théorique spécifiée.
- Comparer une distribution empirique avec une autre distribution empirique ou théorique.

Hypothèses

1. **Hypothèse nulle** (\$ H_0 \$) : Les données suivent la distribution théorique spécifiée.
 2. **Hypothèse alternative** (\$ H_1 \$) : Les données ne suivent pas la distribution théorique spécifiée.
-

Méthodologie

Le test repose sur la comparaison entre la fonction de distribution empirique \$ F_{emp}(x) \$ et la fonction de distribution théorique \$ F_{th}(x) \$.

La statistique du test est donnée par :

$$W^2 = n \int_{-\infty}^{+\infty} [F_{emp}(x) - F_{th}(x)]^2 dF_{th}(x)$$

où \$ n \$ est la taille de l'échantillon.

La statistique calculée est ensuite comparée à la table de Cramer-Von Mises (table spécifique comme pour Kolmogorov-Smirnov). Pour celles et ceux qui veulent en savoir plus : [<https://lemakistatheux.wordpress.com/2013/08/04/test-de-cramer-von-mises/>]

Implémentation sous R

Exemple : Vérification d'une loi normale

```
# Chargement du package goftest
library(goftest)

# Test de Cramer-von Mises pour une loi normale centrée réduite
test_result <- cvm.test(data$ma_var, "pnorm", mean = 0, sd = 1)
```

Annexes Exercice 2 : le test d'Anderson-Darling

Comme le test de Kolmogorov-Smirnov et celui de Cramér-Von Mises, le test d'Anderson-Darling est un test statistique non paramétrique utilisé pour vérifier si un échantillon suit une distribution théorique donnée.

C'est une extension du test de Cramer-von Mises, avec un poids supplémentaire accordé aux queues de la distribution.

Hypothèses

1. **Hypothèse nulle (\$ H_0 \$)** : Les données suivent la distribution théorique spécifiée.
2. **Hypothèse alternative (\$ H_1 \$)** : Les données ne suivent pas la distribution théorique spécifiée.

Méthodologie

La statistique d'Anderson-Darling \$ A^2 \$ peut être exprimée sous la forme suivante :

$$A^2 = n \int_{-\infty}^{\infty} \frac{[F_{\text{emp}}(x) - F_{\text{th}}(x)]^2}{F_{\text{th}}(x)(1 - F_{\text{th}}(x))} dF_{\text{th}}(x)$$

avec :

- \$ F_{\text{emp}}(x) \$: La fonction de distribution empirique.
- \$ F_{\text{th}}(x) \$: La fonction de distribution théorique.
- \$ n \$: La taille de l'échantillon.
- Le terme au dénominateur, \$ F_{\text{th}}(x)(1 - F_{\text{th}}(x)) \$, donne plus de poids aux écarts entre \$ F_{\text{emp}}(x) \$ et \$ F_{\text{th}}(x) \$ dans les queues de la distribution.

Les queues de la distribution (valeurs proches de 0 ou 1 pour \$ F_{\text{th}}(x) \$) reçoivent donc un poids plus élevé dans l'intégrale. Cela rend le test d'Anderson-Darling particulièrement sensible aux écarts dans ces régions, ce qui est utile dans des applications où les queues sont importantes (par exemple en modélisation du risque).

Les p-valeurs sont obtenues à partir de simulations ou de tables spécifiques.

Annexes Exercice 3 : le test ANOVA

Hypothèses du Test ANOVA

1. **Hypothèse nulle** (H_0) :

Les moyennes des groupes sont égales :

$H_0 : \mu_1 = \mu_2 = \dots = \mu_k$ Où k représente le nombre de groupes.

2. **Hypothèse alternative** (H_a) :

Au moins une des moyennes est différente.

Prérequis du Test ANOVA

Pour assurer la validité des résultats, les conditions suivantes doivent être respectées :

- Les observations doivent être **indépendantes** entre les groupes et à l'intérieur de chaque groupe.
- Les résidus (différences entre les observations et les moyennes prévues par le modèle) doivent suivre une **distribution normale** dans chaque groupe.
- Les variances des groupes doivent être **homogènes** (égales).